QR AI Lab

使用手冊：各資料類型的訓練與推論

表格 · 影像 · 序列 · 光譜 · 文字

版本 0.2 · 2026-10

本手冊對應 backend v0.1 與 trainer v0.1；介面截圖為第一版畫面，實際版面可能微調。

目錄

1. 平台在做什麼、角色與共通流程
2. 建立任務（Job）：欄位說明與推論模式
3. 資料前處理：選擇步驟並即時預覽
4. 表格資料（TABULAR）
5. 影像資料（IMAGE）：分類、偵測、分割量測、異常、影像品質基準
6. 序列資料（SEQUENCE）
7. 光譜資料（SPECTRUM）
8. 文字資料（TEXT）
9. 看懂結果：指標、leaderboard、log
10. 管理員：角色、資源池、GPU、佇列、使用率歷史、模型庫
11. 常見問題
12. 附錄：API 速查

1. 平台在做什麼、角色與共通流程

QR AI Lab 是公司內部的 AI 模型實驗室：你提出專案申請，管理員核准並分配運算配額，之後在專案裡指定資料、選模型（或交給 AutoML）訓練，把訓練好的模型拿來推論。平台不會保存你的資料集：上傳檔與從你的 MinIO / URL 抓下來的副本只存在於任務執行期間，任務一結束就刪除；保存的只有訓練產物、log 與指標。

1.1 角色

角色	能做什麼
一般使用者（user）	提出專案申請、在討論區發問；成為專案成員後可建立資料來源與任務
專案 owner / maintainer	管理成員、封存專案、設定預設模型
專案 member	建立資料來源、上傳、建立 / 取消任務、設定預設模型
專案 viewer	只讀：看任務、log、下載產物
管理員（admin）	日常營運：在專案的「申請」分頁審核、重排佇列、強制中斷 / 重新執行 / 刪除任何任務、關閉或刪除討論串；資源池、配額、模型庫只能看
系統管理員（superadmin，固定一位，由 SUPERADMIN_USERNAME 指定）	admin 的一切，加上：設定總資源池與工具池、在專案「設定」分頁調配額、刪除專案、上傳 / 匯入模型庫權重、把使用者設成 admin / user、強制釋放 GPU 顯存

登入方式由系統管理員設定：開發 / 過渡期用平台自己的帳號密碼；正式環境按「使用公司帳號登入（Keycloak）」走公司單一登入，第一次登入會自動建立帳號（Keycloak 只提供身分），角色由系統管理員在「使用者」頁指定。

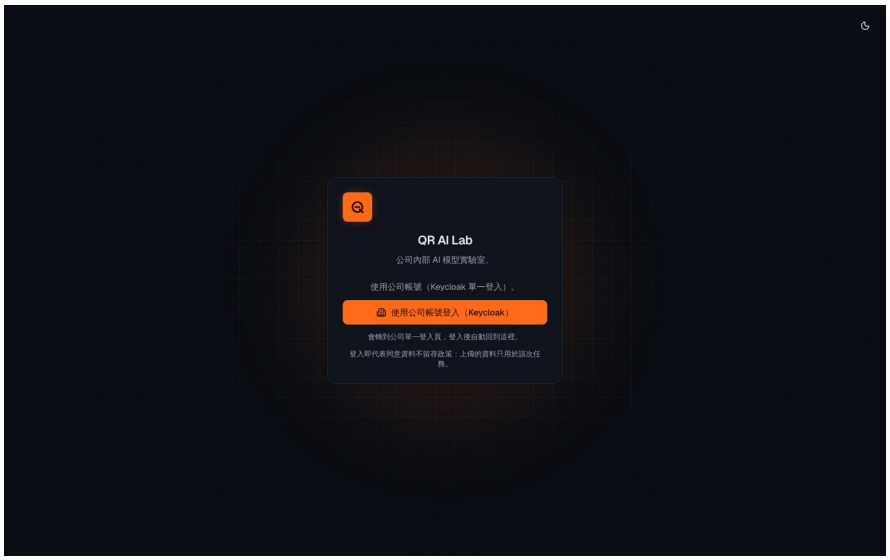


圖 0　正式環境的登入頁（Keycloak）

1.2 從申請到推論的流程

1. 登入（過渡期為本地帳號；之後接公司 Keycloak）。
2. 「專案申請」填題目、資料類型（TABULAR / IMAGE / SEQUENCE / TEXT / SPECTRUM）、任務類型、需要的 GPU / CPU / 記憶體 / 儲存。
3. 管理員審核：核准時指定專案代號（slug）、配額與成員，系統自動建立專案。

4. 專案 →「資料來源」：新增你自己的 MinIO / URL（只存連線資訊，憑證加密），或在建立任務時一次性上傳檔案。
5. （可選）在上傳後選幾個資料前處理步驟，平台抽樣套用給你看前後對照。
6. 「新建任務」：選訓練，資料來源 + spec（例如目標欄位），自動模式（AutoML）或手動選模型，送出後進入全域佇列。
7. 任務頁看即時 log、進度、指標；完成後在「模型」頁看到產物，第一個模型自動成為預設模型。
8. 「新建任務」選推論：選模型、推論模式、輸入資料（直接貼 JSON、上傳或資料來源），完成後下載 predictions.csv。



圖 1　專案申請表單（填好的例子）

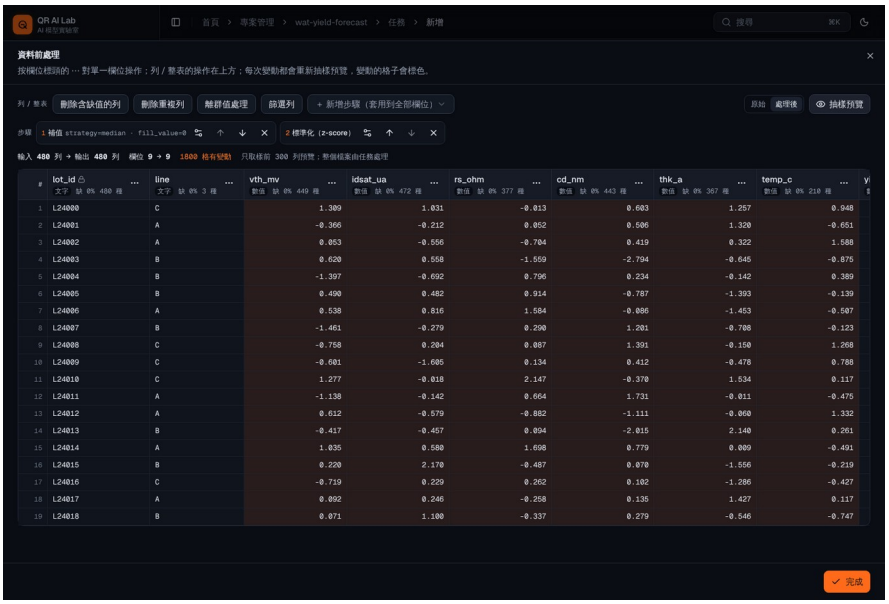


圖 2　新建任務精靈：欄位與前處理（抽樣預覽處理前 / 後）



圖 3　任務頁：執行中的即時 log

2. 建立任務（Job）：欄位說明與推論模式

訓練與推論都是「任務」，共用同一條全域佇列；管理員可以重排佇列或強制中斷。每個任務都有 log 檔與即時事件。

欄位	說明
kind	train（訓練）或 inference（推論）
name	任務名稱，方便辨識
input.kind	upload（一次性上傳，任務結束即刪）、data_source（你的 MinIO / URL）、inline（推論用的小量 JSON）
input.spec	資料的描述：target（目標欄）、features、categorical、text_column、label_column、window / stride、label、preprocess（前處理步驟）…依資料類型而定，見各章
mode	訓練：auto（AutoML，試多個候選模型並搜尋超參數）或 manual（指定 model_family + config）
model_family	手動模式的模型家族，例如 tabular.xgboost、vision.yolo、spectrum.masked_autoencoder
config	手動模式的超參數（如 epochs、max_depth）；推論用 config.mode 指定推論模式、config.k 等選項
artifact_id	推論用：要用哪個模型產物（預設模型會自動帶入）
requested_gpu / cpu / memory_mb	資源請求，不能超過專案配額；需要 GPU 的家族至少 1 GPU
timeout_minutes	逾時自動中止（預設 240 分鐘）

2.1 推論模式（config.mode）

先想清楚推論時要做什麼，再回推要訓練哪個模型。不填 mode 就用該模型支援的第一個模式。

模式	白話	輸出	哪些模型
predict	給一筆資料回類別或數值	prediction、confidence / 各類機率	表格、文字、DINO few-shot、YOLO 分類、光譜 MAE 迴歸頭
score	這筆資料正不正常	anomaly_score、is_anomaly	Isolation Forest、Patch AE、光譜 MAE、PatchCore（附熱圖）、影像品質基準
compare	整批影像與黃金機台基準比對	每個指標 match / drift / fail 與總判定	影像品質基準
embed	資料 → 向量	embedding、embeddings.npy	所有深度學習家族、影像品質基準
retrieve	找最相似 / 最不相似、有多新	most_similar、least_similar、novelty	Patch AE、光譜 MAE、DINO few-shot
detect / segment	圖裡東西在哪、哪些像素	框、遮罩、標註圖	YOLO
measure	從遮罩算幾何量	面積、寬高、等效直徑（可換算 nm）	YOLO segmentation

模式	白話	輸出	哪些模型
extend	不重訓加入新類別	新版本模型（自動設為預設）	DINO few-shot

2.2 任務狀態

queued（排隊）→ scheduled（已分配資源）→ running（執行中）→ succeeded / failed / cancelled。排隊中會顯示等待原因（例如專案同時執行上限、資源池 GPU 不足）。

3. 資料前處理：選擇步驟並即時預覽

每種資料類型都有一組可選的前處理步驟。你在上傳後選步驟與參數，平台會從上傳檔抽樣（表格最多 5000 列統計、影像最多 8 張、曲線最多 50 條）套用並回傳前後對照；確認後把步驟放進任務的 input.spec.preprocess。訓練時這些步驟會「學」在訓練資料上（例如補值用的中位數、標準化的平均與標準差、對位的參考影像），並存進模型；推論時自動沿用同一組步驟與數值，不必再選。

> **注意**　偵測 / 分割任務不能用會改變座標的步驟（縮放、裁切、翻轉、旋轉、對位），因為標註框會失效；平台會直接拒絕。

3.1 可用步驟

資料類型	步驟（op id）
TABULAR	補值 tabular.impute、刪除含缺值列 tabular.drop_missing、離群值截斷 / 刪除 tabular.clip_outliers、標準化 tabular.standardize、歸一化 tabular.minmax、對數 tabular.log、轉數值 tabular.to_numeric、篩選列 tabular.filter_rows、移除 / 只保留欄位、刪除重複列
IMAGE	縮放 image.resize、灰階、裁切 image.crop / center_crop、自動對比、直方圖均衡、Gamma、百分位拉伸 image.stretch、去雜訊 image.denoise、銳利化、反相、翻轉、旋轉、對位 image.align（相位相關求平移，參考影像存進模型）
SEQUENCE / SPECTRUM	重取樣 sequence.resample、裁切範圍、補缺值、Savitzky–Golay 平滑、移動平均、微分 sequence.derivative、基線校正（多項式 / 滾動最小值）、去趨勢、SNV、每條歸一化、MSC sequence.msc、整體標準化、截斷數值
TEXT	轉小寫、清理空白、移除標點 / 網址 / 數字、截斷長度、正規表達式取代、刪除空白文字、刪除重複文字

3.2 操作

1. 上傳檔案後，在「前處理」區塊新增步驟，調整參數。
2. 按「預覽」：表格看每欄缺值數、平均、標準差、最小最大與前幾列；影像看縮圖；曲線看前後曲線。
3. 滿意後送出任務；任務 log 會印出 preprocess (fit): … 與列數變化。
4. 推論任務若使用這個模型，平台會拒絕再指定 preprocess（因為模型已內含），避免重複處理。

> **建議**　先用少量步驟。補值與標準化對表格模型（尤其線性、SVM）幫助最大；影像先做自動對比 / 百分位拉伸再談其他；光譜常用 SNV 或 MSC + Savitzky–Golay。

3.3 不用專案的資料前處理服務

左側選單「資料前處理」：不需要專案也能用。選資料類型 → 上傳檔案 → 加入步驟並抽樣預覽（即時，只取樣）→ 「建立前處理任務」。整個檔案的處理是公共工具池裡的任務（不佔用任何專案的配額，每人同時有數量上限）：和其他任務一樣排隊、有即時 log；完成後到「工具」裡的任務頁下載 zip（processed.csv / .npy / images/、pipeline.json、summary.json）。上傳檔在任務結束時刪除，結果 zip 下載一次就刪、沒下載的在管理員設定的時間（預設 24 小時）後刪。

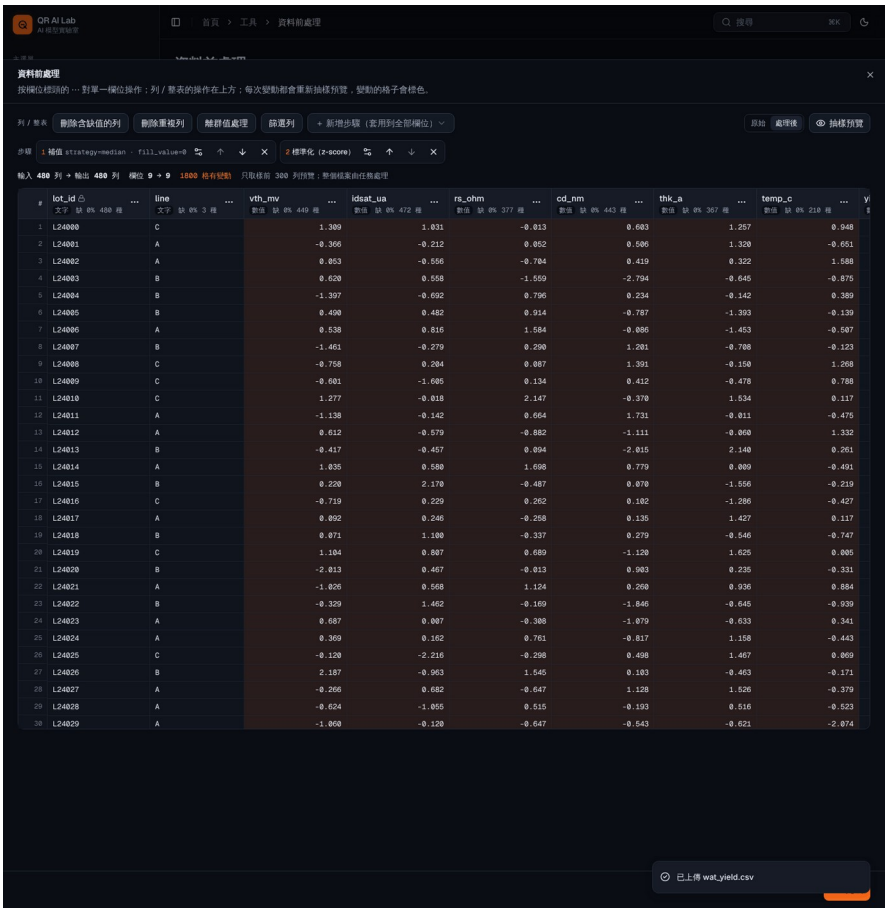


圖 3a　資料前處理服務：上傳、步驟、抽樣預覽

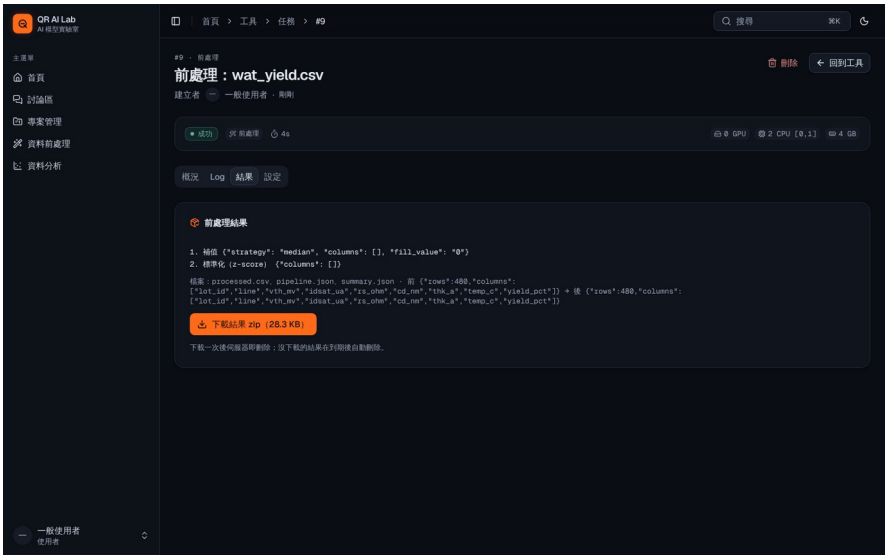


圖 3b　前處理任務頁：log、步驟、一次性下載

3.4 資料分析服務

左側選單「資料分析」：上傳資料、選分析類型，由任務算出報告。表格資料探勘：欄位概況、相關矩陣與高相關欄位對、VIF 共線性、指定目標欄位後每個欄位的解釋力（互資訊、相關性、隨機森林置換重要度）與疑似洩漏，最後給建議（補值、該丟哪些欄位、適合的模型）。影像品質分析：把不同機台 / 條件的影像放在 zip 的不同子資料夾，報告列出每個 IQA 指標在群組間的飄移比與 p 值、各群組中位數、embedding 的散佈圖與群組相似度、偏離群組的影像，以及該監控哪些指標。

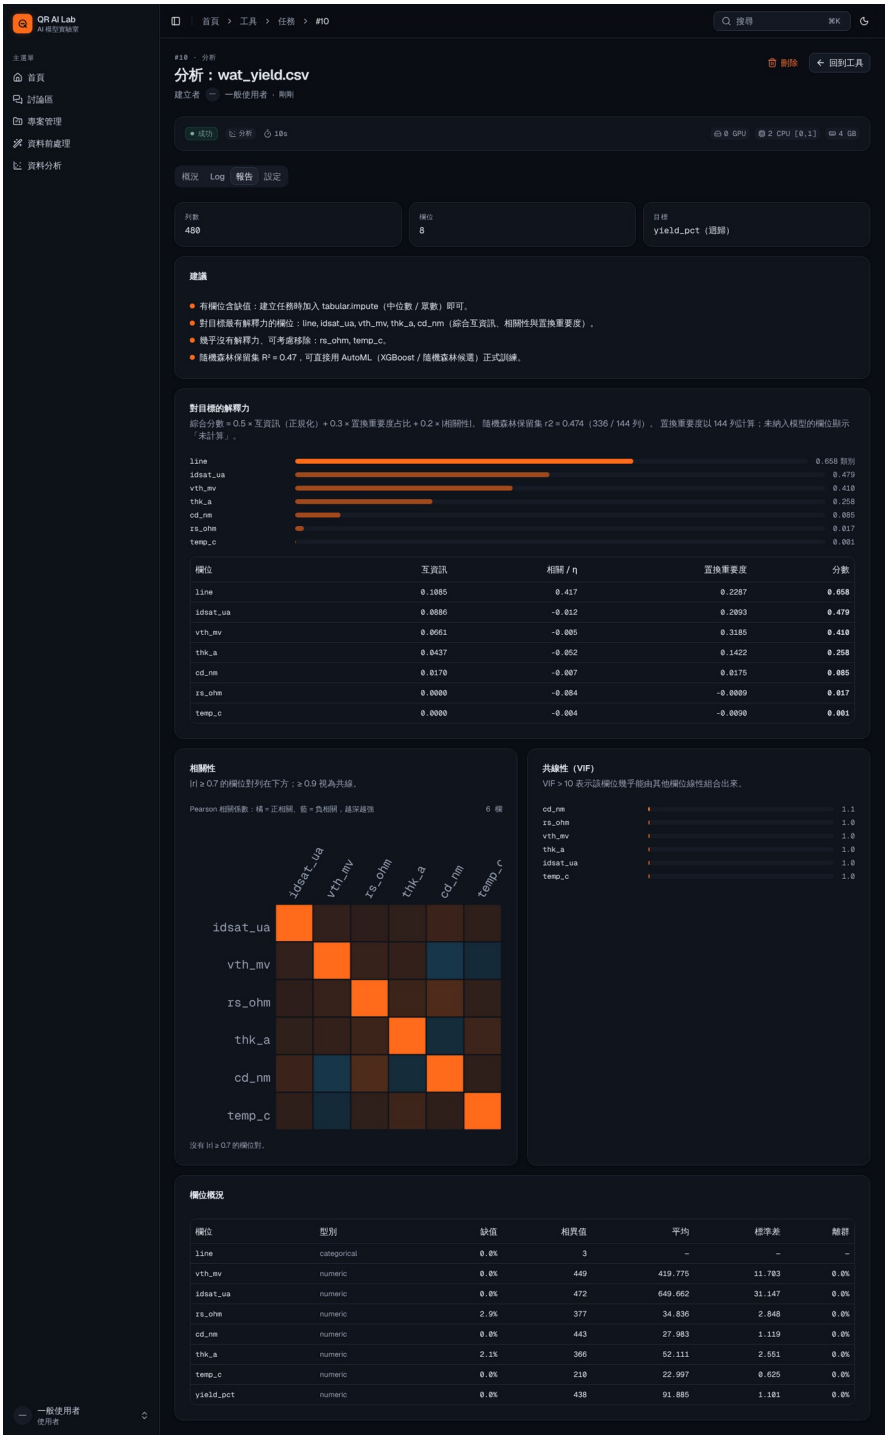


圖 3c　表格資料探勘報告



圖 3d　影像品質分析報告（三台機台）

4. 表格資料（TABULAR）

4.1 準備資料

- csv 或 parquet，第一列是欄名；每列一筆樣本、每欄一個特徵。
- spec.target：目標欄（分類用類別、迴歸用數值）；異常偵測不需要目標，但若有 0 / 1 或 normal / anomaly 標籤可填 target 供評估。
- 可選 spec.features（只用這些欄）、spec.categorical（類別欄；不填會自動偵測文字欄）、spec.drop_columns、spec.id_column（識別欄，不參與訓練，推論結果會帶回）。
- 缺值可以留空（平台會補），類別欄自動 one-hot。建議 ≥ 100 列；XGBoost 建議 ≥ 200 列。

4.2 模型

家族	適合	備註
tabular.xgboost	大多數分類 / 迴歸	表格首選；給特徵重要度
tabular.random_forest	小資料、不想調參	穩健；特徵重要度
tabular.linear	想解釋、當基準線	邏輯迴歸 / Ridge；秒級
tabular.svm	小資料、特徵多	> 5 萬列會很慢
tabular.isolation_forest	只有正常資料找離群	任務類型 anomaly_detection，推論 score

4.3 訓練（AutoML 範例：WAT 參數 → 良率）

1. 資料來源：上傳 wat.csv 或指定 MinIO 路徑。
2. 任務類型 regression，spec.target = yield_pct，可加 preprocess：impute + clip_outliers。
3. mode = auto，CPU 2、記憶體 4 GB、GPU 0。AutoML 會依序試 XGBoost、隨機森林、線性、SVM（> 5 萬列自動略過 SVM）。
4. 完成後看 leaderboard：每個 trial 的家族、參數、rmse；最佳模型自動匯出並登記，report/feature_importance.json 列出重要特徵。
5. 候選家族：XGBoost、CatBoost（另一個梯度提升樹，小資料與類別欄較穩）、TabPFN（預訓練好的表格 transformer，fit 只是把訓練列放進上下文、沒有超參數要調，幾十到幾千列常常直接最準；權重來自模型庫，> 1 萬列自動跳過）、隨機森林、線性、SVM。

4.4 推論

- inline：直接貼 rows，例如 [{"x1": 1.2, "x2": 0.3, "line": "A"}]；欄位缺的會補缺值，多的會忽略。
- upload / data_source：同格式的 csv（不需要目標欄）。
- 結果 predictions.csv：id、prediction、confidence（分類另有 proba_<類別>）；異常偵測：anomaly_score、is_anomaly。

```
{"kind":"train","name":"wat-yield","task_type":"regression","mode":"auto",
 "input":{"kind":"upload","upload_id":12,"spec":{"target":"yield_pct",
   "preprocess":[{"op":"tabular.impute"},{"op":"tabular.clip_outliers","params":
{"action":"clip"}}]}},
 "requested_gpu":0,"requested_cpu":2,"requested_memory_mb":4096}
```

5. 影像資料（IMAGE）

5.1 準備資料

任務	格式	備註
classification	zip：<類別>/*.jpg（可再分 train/、val/）	few-shot 每類 ≥ 3 張；YOLO 分類每類 ≥ 50 張
detection / segmentation	zip：YOLO 格式 images/、labels/、data.yaml	分割用多邊形標註
anomaly_detection	zip：good/（或 normal/、ok/）為正常；其他資料夾視為異常（只用於評估）	PatchCore 與影像品質基準都用這個格式

5.2 分類：bin code 會一直增加 → DINO few-shot

- 家族 vision.dino_fewshot：凍結 DINOv2 或 DINOv3（config.backbone = dinov2-small / dinov2-base / dinov3-vits16 / dinov3-vitb16，權重來自模型庫）取特徵，每類存一個原型；每類幾張範例就能用。需要 GPU 1。DINOv3 的 patch 較細、SEM / TEM 紋理通常較穩，但權重是 gated（管理員要先在 Hugging Face 接受授權）。
- 推論 predict：回最近的類別與相似度；config.min_similarity 可讓低相似度的回 unknown。retrieve：找最相似 / 最不相似的範例影像，表單可選方向（只找最相似、只找最不相似、兩者都列）與每筆回幾個；最不相似用來找離群或挑下一批要標註的。
- 看模型在看哪裡：predict / retrieve 每張影像都會多一張「模型關注的區塊」疊圖；在結果列點開樣本，疊圖會以可調透明度覆蓋在你瀏覽器裡的原圖上（紅 = 影響判斷最多的位置；只覆蓋模型實際看到的中央區域）。紅色落在背景或資訊列時，先用前處理 image.crop 切掉再訓練。
- 新增 bin code 不用重訓：建立推論任務，config.mode = extend，輸入新類別的資料夾 zip，平台產生新版本模型並設為預設。

5.3 分類：類別固定、每類幾十張以上 → DINO 微調

- 家族 vision.dino_finetune：真的訓練 DINOv2 / DINOv3 做分類。config.method = linear 只訓練分類頭（最快）；lora 在注意力層加低秩轉接器一起訓練（SEM / TEM 這類和自然影像差很多的資料用這個，產物只有幾 MB）；full 全參數微調（每類上百張、顯示卡記憶體夠時）。
- 其他參數：epochs、lr、rank（LoRA 秩）、batch、augment（訓練時的隨機增強，自己挑：hflip、vflip、rotate90、crop、brightness、contrast；方向有意義的影像不要加翻轉 / 旋轉）；自動模式會在 linear / lora 之間搜尋。推論 predict 回 prediction、confidence、top3（config.min_confidence 可讓低信心的回 unknown），並附 Grad-CAM 疊圖（分類頭對每個區塊的貢獻）；retrieve 找最像 / 最不像的訓練影像（可選方向）；embed 輸出特徵向量。
- few-shot 與微調怎麼選：類別會一直增加、每類只有幾張 → few-shot；類別固定、每類幾十張以上、要更準 → 微調。

5.4 分類：類別固定、資料多 → YOLO 分類

- 家族 vision.yolo，task classification；config.model = yolov8n / s / m、imgsz、epochs；pretrained = true 從模型庫的 yolov8s-cls.pt 微調，false 從頭訓練。
- 指標 accuracy、f1_macro；推論 predict 回 prediction、confidence、top5。

5.5 偵測與分割量測

- YOLO 偵測：推論 detect，每個物件一列（class、confidence、x1 y1 x2 y2）；output/images/ 有標註圖。
- YOLO 分割：推論 segment 或 measure；measure 多給 area_px、width_px、height_px、equiv_diameter_px，config.pixel_size（每像素的實際長度，例如 2.5 nm）會再給 *_phys 欄。

5.6 只有良品影像 → PatchCore 異常偵測

- 家族 vision.dino_patchcore（GPU）：正常影像的 patch 特徵建記憶庫；推論 score 回 anomaly_score、is_anomaly、hot_patch_row / col，並輸出 heatmaps/*.png。

5.7 影像品質基準與機台比對（tool matching）

場景：用黃金機台的一批影像建立「影像品質」基準與浮動範圍，其他機台調機後拍同類樣品，檢視每個品質指標是否落在基準範圍內。不需要標註、不需要 GPU、不需要預訓練權重。

- 家族 vision.image_quality，task anomaly_detection。訓練資料：黃金機台影像放 good/（或整包都是正常）。
- 17 個無參考指標：清晰度（Laplacian 變異、Tenengrad、Brenner）、雜訊標準差、訊噪比、對比（RMS、Michelson）、亮度（平均、P1、P99）、過暗 / 過亮飽和比例、亮度熵、高頻能量比、頻譜斜率、方向性（梯度 x/y、頻譜水平 / 垂直，可反映像散或掃描方向問題）。
- 基準 = 每個指標的穩健中位數與尺度（MAD），浮動範圍 = 中位數 ± z_threshold × 尺度（預設 3）；另以 Mahalanobis 距離做整體判定，門檻取黃金影像距離的 P99。產物 report/baseline_ranges.csv 列出每個指標的範圍。
- 推論 compare：把調機後機台的一批影像丟進來，每個指標給 golden_median、golden_low / high、test_median、effect（偏移多少個尺度）、KS 檢定 p 值、in_range_ratio 與 verdict（match / drift / fail）；總判定 pass / drift / fail，並列出 failed_metrics、drifted_metrics。output/comparison.csv 就是調機報告。
- 推論 score：單張影像的指標、z 分數、距離與 is_anomaly，用來做日常監控。
- 該調什麼：17 個指標分成五個面向（對焦 / 清晰度、雜訊、亮度、對比、方向性 / 像散），結果頁的「建議調整」卡片依偏離的面向與方向給出動作（例如比基準模糊 → 重新對焦、校正像散、確認工作距離；方向性不同 → stigmator X / Y、掃描方向）；score 的每一列也有 advice 欄。
- 偏離在哪裡：每張影像有一張「偏離基準最多的區塊」疊圖（偏離最多的指標依 8 × 8 方格著色），點開樣本就疊在原圖上：整張一致 = 機台設定，集中在某一角 = 樣品不平、帶電或掃描問題。
- 同一樣品在兩台機台逐張比對（全參考）：zip 放 golden/（參考機台）與 target/ 兩個資料夾、同檔名，compare 會自動逐張對位後算 PSNR、SSIM、MS-SSIM、GMSD，結果頁多一張「與參考影像逐張比對」卡片（pass / drift / fail），output/paired.csv 逐張；疊圖改成差異最大的區塊。config.paired = false 可關閉。
- 選項：config.z_threshold、config.effect_warn（預設 1）、config.effect_fail（預設 2）、config.alpha（KS 顯著水準，預設 0.01）、config.ssim_warn（0.9）/ ssim_fail（0.7）、config.maps（疊圖，預設開）。

> **建議**　同一基準只適用於同類樣品與同放大倍率；不同製程層或倍率請分別建基準。影像上若有資訊列（SEM 底部文字），先用前處理 image.crop 切掉再建基準。

6. 序列資料（SEQUENCE）

- 格式：csv 長表 series_id,t,feature1,feature2…（spec.window、spec.stride 切視窗；spec.series_id、spec.time 指定欄名）或 npy（N × T × C）。
- 家族 sequence.patch_autoencoder：patch 嵌入 + 位置編碼 + 整段視窗壓到一個 latent，「峰值移位」也能抓到；CPU 可跑，GPU 更快。
- 訓練：task anomaly_detection；有 spec.label（normal / anomaly）時只用正常視窗訓練，異常視窗進驗證集算 auroc。
- 推論：score（異常分數、門檻可用 config.threshold 覆寫）、retrieve（找歷史最像 / 最不像的 run，config.k；config.reference = self 可讓輸入互相比）、embed（向量給 BI 分群）。
- 前處理常用：sequence.fill_nan、sequence.detrend、sequence.standardize。

7. 光譜資料（SPECTRUM）

- 格式：spectrum_csv 寬表（每列一條光譜，欄 = 波長）或 npy（N × T）；可選 spec.label（異常標籤、迴歸目標或類別）。推論時長度不同的光譜會自動重取樣到訓練長度。
- 有量測值或類別先用 spectrum.pls：PLS 迴歸（光譜 → CD / 膜厚 / 濃度）與 PLS-DA 分類（PLS 分數 + 邏輯迴歸）；幾十筆就能用、秒級、不用 GPU；config.n_components（自動模式搜 2 … 30）；產物 report/vip.csv 列出每個波長的 VIP（> 1 = 真的在用）。
- 家族 spectrum.masked_autoencoder：把光譜切 patch、隨機遮蔽再重建，學到的 embedding 當光譜鑑別器；候補 sequence.patch_autoencoder。
- 光譜鑑別器（OCD / 橢圓偏光）：訓練 anomaly_detection → 推論 retrieve 回每條光譜最像 / 最不像的黃金樣本 id、max_similarity、novelty，summary.most_novel 直接列出最可疑的；score 看異常；定期跑 retrieve 追蹤 max_similarity 中位數可看漂移。
- 光譜 → CD / 膜厚（資料多時）：task regression + spec.label 為量測值；自動模式先試 PLS，≥ 500 筆再加入 MAE（embedding 接 Ridge 迴歸頭；推論 predict 多回 reconstruction_error，誤差大代表不在訓練分布內，預測值別信）。
- 前處理常用：sequence.savgol、sequence.baseline_rolling_min（螢光背景）、sequence.snv 或 sequence.msc、sequence.crop（去兩端雜訊）。

8. 文字資料（TEXT）

- 格式：jsonl 或 csv，spec.text_column（預設 text）、spec.label_column（預設 label）。
- 分類：AutoML 先試 text.qwen_embedding（凍結的 Qwen3-Embedding 向量 + 邏輯迴歸，幾十筆就能用、沒有 GPU 也跑得動）與 TF-IDF + 邏輯迴歸（tabular.linear）；≥ 300 筆再加入 text.bert_classifier（微調 bert-base-chinese / xlm-roberta-base，需要 GPU）。
- 推論 predict：prediction、confidence、各類機率；embed：向量。
- 找相似工單、新型問題：text.qwen_embedding 的 retrieve（可選只找最相似 / 只找最不相似 / 兩者，每筆回幾個；config.reference = self 讓一批工單互比找重複）；task anomaly_detection 時 score 回 novelty 分數（和歷史紀錄都不像 = 新型問題，門檻 = 歷史文字的 P99）。模型只存向量與 id，不存原文。
- 前處理常用：text.strip_whitespace、text.remove_urls、text.dedupe。

9. 看懂結果：指標、leaderboard、log

任務	主要指標	怎麼讀
分類	f1_macro、accuracy、auroc	f1_macro > 0.8 通常可用；不平衡資料看 f1_macro 不看 accuracy
迴歸	rmse、mae、r2	rmse 要跟目標範圍比；r2 越接近 1 越好
偵測 / 分割	map50_95、map50 / mask_map50_95	map50 > 0.5 可試用
異常偵測	auroc、f1、threshold、flagged_ratio	auroc > 0.9 才可靠；沒標籤時只能看分數分布
影像品質比對	verdict、match_ratio、effect、p_value	effect 絕對值 < 1 且 p > 0.01 為 match；≥ 2 為 fail

- AutoML 的 leaderboard 列出每個 trial 的家族、參數、指標與耗時；最佳 trial 的參數可以直接拿去建手動任務微調。
- log 每行有時間與等級：[SYSTEM] 是排程器（分配資源、啟動、逾時、中斷），[INFO] / [WARN] / [ERROR] 來自訓練程式；每個 epoch / trial 一行。
- 結果不好：先檢查資料（標籤錯、類別極端不平衡、圖片太小、光譜長度不一致），再增加資料，最後才調參。

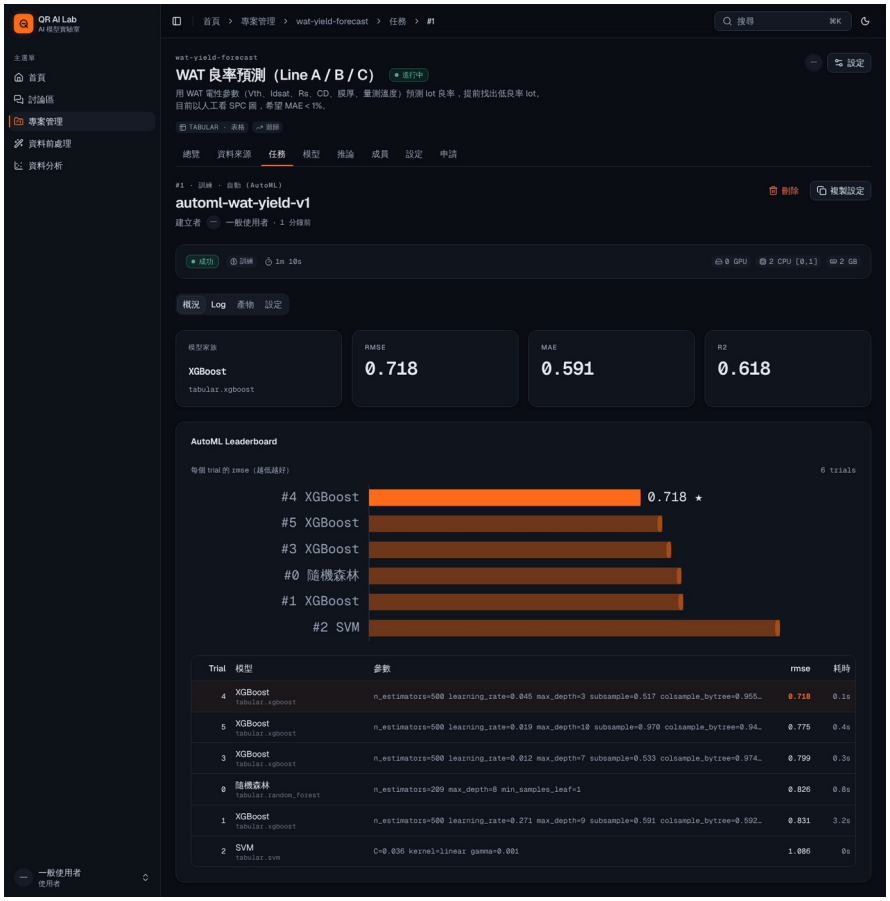


圖 4　訓練完成：最佳模型、AutoML leaderboard

10. 管理員：角色、資源池、GPU、佇列、使用率歷史、模型庫

- 角色（superadmin）：「使用者」頁把人設成 admin / user 或停用；superadmin 只有一位，由伺服器設定 SUPERADMIN_USERNAME 指定，介面上不能指派。Keycloak 只提供身分，不決定角色。
- 總資源池（superadmin）：所有專案合計可用的 GPU 索引、CPU 核心、記憶體與同時執行上限；排程器以此為硬上限，並允許 backfill。「依顯存共用 GPU」打開時，任務建立時填了「每張 GPU 需要的顯存」就能和其他任務共用同一張卡。
- GPU 卡片與重置（superadmin）：每張卡顯示驅動程式讀到的顯存、排程器保留量、放在上面的任務；「重置」可只中斷本系統的任務、連其他程序一起 kill，或執行伺服器設定的 nvidia-smi --gpu-reset。
- 佇列：看排隊與執行中的任務，置頂 / 上下移動重排；每次重排都寫稽核紀錄。
- 強制中斷 / 重新執行 / 刪除（admin 以上）：任務頁與佇列頁都有。重新執行會用相同輸入與設定建立新任務（一次性上傳的任務除外，因為資料已經刪掉）。
- 使用率歷史：節點實際用量、配置給任務的量、GPU 使用率與顯存、各專案占用；可切 1 小時到 30 天，分母可選專案配額 / 資源池 / 系統總量。
- 模型庫（superadmin 才能改）：列出目錄需要的預訓練權重與是否存在，三種帶進來的方式：瀏覽器上傳、伺服器路徑、內網 URL；訓練程序完全離線。權重來源以 Hugging Face Hub 為主（YOLO 偵測版：Ultralytics/YOLOv8；DINOv2 / v3：facebook；BERT；Qwen3-Embedding；TabPFN：Prior-Labs；YOLO 的分割 / 分類權重 Hugging Face 沒有，從 ultralytics 的 GitHub release 抓），有網路的機器用 scripts/fetch_model_zoo.py 一次抓齊（DINOv3 為 gated 模型，要先接受授權並設定 HF_TOKEN，或用 --skip 略過）。
- 專案申請審核（admin 以上）：專案列表以「申請中 / 審核中」篩選就是待審清單；在專案的「申請」分頁開始審核、核准（設定 GPU / CPU / 記憶體 / 儲存配額、同時執行上限與成員）或退回。工具池（superadmin）：所有人前處理 / 分析任務共用的配額與每人同時上限。
- 刪專案（superadmin）：專案設定頁最下方，要輸入 slug 確認；有未結束任務時拒絕。刪討論串（admin 以上）：討論串頁的「刪除」。

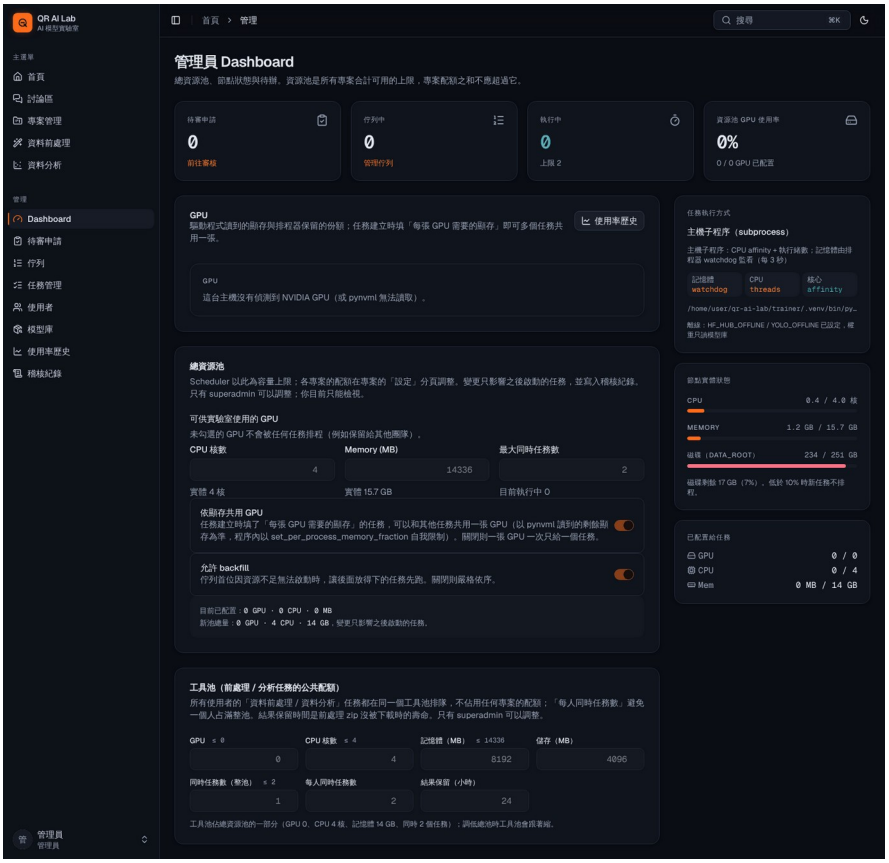


圖 5　管理員儀表板



圖 6　佇列與執行中任務



圖 7　使用者與系統角色



圖 8　任務頁的管理員操作（強制中斷 / 重新執行 / 刪除）

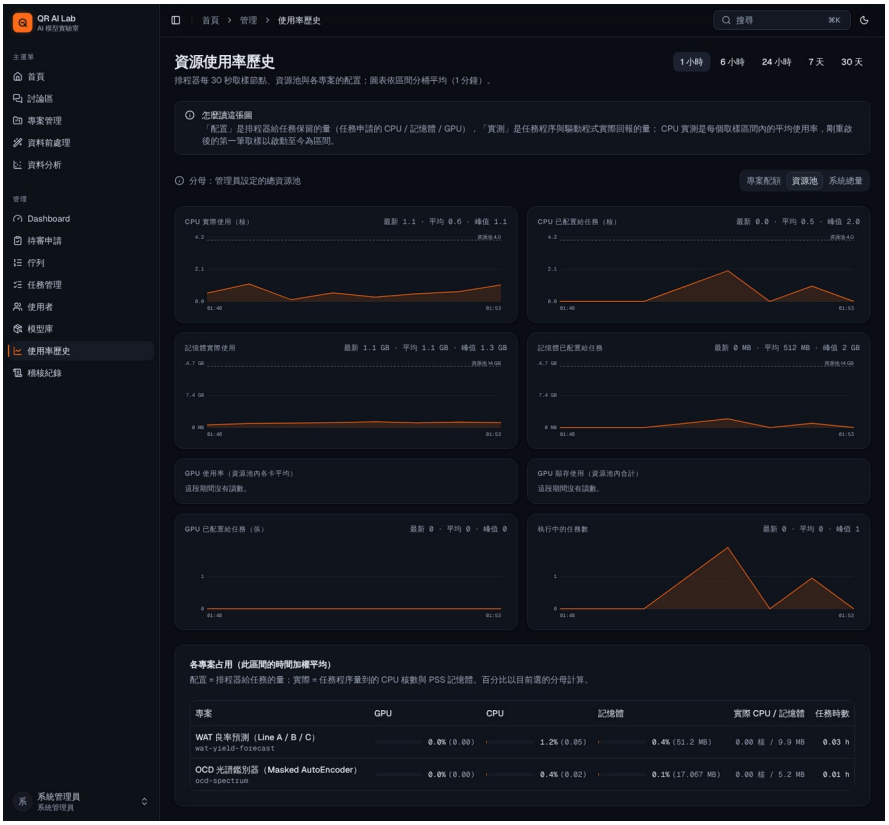

QR AI Lab
AI 模型實驗室
首頁 › 管理 › 使用率歷史
搜尋 ⌘K
主選單
首頁
討論區
專案管理
資料前處理
資料分析
管理
Dashboard
待審申請
佇列
任務管理
使用者
模型庫
使用率歷史
稽核紀錄
系統管理員
系統管理員
資源使用率歷史
排程器每 30 秒取樣節點。資源池與各專案的配置；圖表依區間分桶平均（1 分鐘）。
1 小時
6 小時
24 小時
7 天
30 天
怎麼讀這張圖
「配置」是排程器給任務保留的量（任務申請的 CPU / 記憶體 / GPU），「實測」是任務程序與驅動程式實際回報的量；CPU 實測是每個取樣區間內的平均使用率，剛重啟後的第一筆取樣以啟動至今為區間。
分母：管理員設定的總資源池
專案配額
資源池
系統總量
CPU 實際使用（核）
最新 1.1 · 平均 0.6 · 峰值 1.1
CPU 已配置給任務（核）
最新 0.0 · 平均 0.5 · 峰值 2.0
記憶體實際使用
最新 1.1 GB · 平均 1.1 GB · 峰值 1.3 GB
記憶體已配置給任務
最新 0 MB · 平均 512 MB · 峰值 2 GB
GPU 使用率（資源池內各卡平均）
這段期間沒有讀數。
GPU 顯存使用（資源池內合計）
這段期間沒有讀數。
GPU 已配置給任務（張）
最新 0 · 平均 0 · 峰值 0
執行中的任務數
最新 0 · 平均 0 · 峰值 1
各專案占用（此區間的時間加權平均）
配置 = 排程器給任務的量；實際 = 任務程序量到的 CPU 核數與 PSS 記憶體。百分比以目前選的分母計算。
專案
GPU
CPU
記憶體
實際 CPU / 記憶體
任務時數
WAT 良率預測（Line A / B / C）
wat-yield-forecast
0.0% (0.00)
1.2% (0.05)
0.4% (51.2 MB)
0.00 核 / 9.9 MB
0.03 h
OCD 光譜鑑別器（Masked AutoEncoder）
ocd-spectrum
0.0% (0.00)
0.4% (0.02)
0.1% (17.067 MB)
0.00 核 / 5.2 MB
0.01 h

圖 9　資源使用率歷史

11. 常見問題

狀況	原因與處理
任務一直 queued	看等待原因：專案同時執行上限、GPU 配額、資源池不足；請管理員調整或等待
GPU_REQUIRED	選的家族需要 GPU（YOLO、DINO、BERT），申請時 requested_gpu ≥ 1；或改用 CPU 家族
模型庫缺少權重	log 會說缺哪個檔與預期路徑；請管理員執行 fetch_model_zoo.py 並放到 MODEL_ZOO_ROOT
STORAGE_QUOTA_EXCEEDED	專案儲存已滿；刪除舊產物或請管理員調高配額
PREPROCESS_INVALID	前處理步驟不適用於此資料類型 / 任務，或欄位不存在；用預覽確認
推論欄位對不上	表格推論會補缺的欄位並忽略多的欄位；確認欄名大小寫一致
影像品質 compare 全部 fail	確認放大倍率、樣品種類與基準一致；先用前處理裁掉資訊列；基準影像至少 30 張
任務 failed：timeout	調高 timeout_minutes 或縮小資料 / epochs

12. 附錄：API 速查

前綴 /api/v1，所有請求帶 Authorization: Bearer <token>。

```
POST /auth/login {username, password}                    登入
GET  /catalog                                            資料類型、任務、模型家族、AutoML 規則
GET  /catalog/preprocess?data_type=TABULAR               可用前處理步驟與參數
POST /projects                                           專案申請（建立 pending 專案）；/{slug}/approve 管理員核准
POST /projects/{slug}/data-sources                       新增 MinIO / URL 資料來源；/{id}/check 連線檢查
POST /projects/{slug}/uploads  (multipart)               一次性上傳
POST /projects/{slug}/uploads/{id}/preview {steps,sample,spec}   前處理抽樣預覽
POST /projects/{slug}/jobs                               建立訓練 / 推論任務（202）
GET  /jobs/{id} | /logs | /events (SSE) | /artifacts     任務狀態、log、即時事件、產物
POST /jobs/{id}/cancel                                   取消
GET  /artifacts/{id}/download                            下載產物（目錄會打包成 zip）
GET  /admin/queue | PUT /admin/queue/order | POST /admin/jobs/{id}/stop   管理員
GET  /admin/model-zoo                                    模型庫狀態
```